

ট্রান্সফর্মার মডেলে একাধিক ইনপুটকে কীভাবে একসাথে বা 'ব্যাচ' (**Batch**) হিসেবে প্রসেস করা যায়, তা বিস্তারিতভাবে ব্যাখ্যা করা হয়েছে। নিচে এর মূল ধাপগুলো সহজভাবে বুঝিয়ে বলা হলো:

১. ব্যাচিং-এর প্রয়োজনীয়তা ও সমস্যা

সাধারণত আমরা যখন মডেলে একাধিক বাক্য পাঠাই, সেগুলোর দৈর্ঘ্য সমান হয় না। কিন্তু মেশিন লার্নিং মডেলে ডেটা পাঠানোর জন্য আমাদের টেনসর (**Tensor**) তৈরি করতে হয়, যা অবশ্যই '**Rectangular**' বা আয়তাকার হতে হবে। অর্থাৎ, একটি ব্যাচের সব ইনপুটের দৈর্ঘ্য সমান হওয়া বাধ্যতামূলক, অন্যথায় এরর (**Error**) দেখা দেবে।

২. সমাধান: প্যাডিং (**Padding**)

ভিন্ন দৈর্ঘ্যের বাক্যগুলোকে সমান করার জন্য ছোট বাক্যগুলোর শেষে বিশেষ কিছু টোকেন যোগ করা হয়, একেই বলা হয় প্যাডিং।

- **Padding Token:** এই কাজের জন্য যেকোনো সংখ্যা ব্যবহার করা যায় না; মডেলটি যে নির্দিষ্ট **pad_token_id** দিয়ে প্রি-ট্রেনিং করা হয়েছে, সেটিই ব্যবহার করতে হয়।
- **বিকল্প (Truncation):** বড় বাক্যকে ছোট করার জন্য **Truncation** করা যায়, তবে এতে গুরুত্বপূর্ণ তথ্য হারিয়ে যাওয়ার ঝুঁকি থাকে। সাধারণত মডেলের সর্বোচ্চ ক্ষমতার চেয়ে বড় বাক্য হলে তবেই এটি করা হয়।

৩. অ্যাটেনশন মাস্ক (**Attention Mask**) কেন প্রয়োজন?

শুধু প্যাডিং করলেই সমস্যার সমাধান হয় না। ট্রান্সফর্মার মডেলের অ্যাটেনশন লেয়ার (**Attention Layers**) একটি বাক্যের প্রতিটি টোকেন তৈরি করার সময় ওই বাক্যের অন্য সব শব্দের দিকে লক্ষ্য রাখে।

- যদি মডেলে শুধু প্যাডিং যুক্ত বাক্য পাঠানো হয়, তবে মডেল ওই প্যাডিং টোকেনগুলোকেও বাক্যের অংশ মনে করে এবং সেগুলোর ওপর ভিত্তি করে আউটপুট দেয়।
- এর ফলে একই বাক্যের আউটপুট প্যাডিং থাকা অবস্থায় এবং প্যাডিং ছাড়া অবস্থায় আলাদা হয়ে যায়, যা কাম্য নয়।

৪. অ্যাটেনশন মাস্কের কাজ

এই সমস্যা সমাধানের জন্য **Attention Mask** ব্যবহার করা হয়। এটি মূলত ১ এবং ০ দিয়ে তৈরি একটি টেনসর:

- **১ (Ones):** নির্দেশ করে যে এই টোকেনগুলো আসল শব্দ এবং অ্যাটেনশন লেয়ারের এদের বিবেচনা করা উচিত।
- **০ (Zeros):** নির্দেশ করে যে এই টোকেনগুলো প্যাডিং এবং অ্যাটেনশন লেয়ারের এগুলোকে এড়িয়ে চলা বা ইগনোর করা উচিত।

৫. স্বয়ংক্রিয় পদ্ধতি

আপনি যখন একাধিক বাক্যকে টোকেনাইজ করার সময় **padding=True** ফ্ল্যাগটি ব্যবহার করেন, তখন এটি স্বয়ংক্রিয়ভাবে ছোট বাক্যগুলোতে প্যাডিং যোগ করে এবং প্রয়োজনীয় অ্যাটেনশন মাস্ক তৈরি করে দেয়।

সংক্ষেপে, ভিন্ন ভিন্ন দৈর্ঘ্যের বাক্যকে একসাথে প্রসেস করার জন্য প্যাডিং এবং সেই প্যাডিংকে মডেলের কাছ থেকে আড়াল করার জন্য অ্যাটেনশন মাস্ক ব্যবহার করা অপরিহার্য।