

# Building a Model Card

## Model Card কী এবং কেন গুরুত্বপূর্ণ?

Model card হলো একটি ডকুমেন্ট (সাধারণত **README.md** ফাইল), যা একটি model repository-তে **model** এবং **tokenizer** ফাইলের মতোই গুরুত্বপূর্ণ।

এটি:

- Model-এর কেন্দ্রীয় ডকুমেন্টেশন
- অন্যদের জন্য model পুনঃব্যবহারযোগ্য (reusable) করে
- ফলাফল পুনরুৎপাদনযোগ্য (reproducible) করে
- সীমাবদ্ধতা, bias ও প্রযোজ্য ক্ষেত্র পরিষ্কার করে
- অন্যদের উপর ভিত্তি করে কাজ (artifact building) করতে সহায়তা করে

সংক্ষেপে: Model card ছাড়া model প্রকাশ করা মানে গুরুত্বপূর্ণ প্রেক্ষাপট বাদ দেওয়া।

## কেন Training ও Evaluation ডকুমেন্ট করা জরুরি?

Training ও evaluation প্রক্রিয়া ডকুমেন্ট করলে:

- অন্যরা বুঝতে পারে model থেকে কী ধরনের performance আশা করা যায়
- কোন dataset ব্যবহার হয়েছে তা জানা যায়
- preprocessing/postprocessing কী করা হয়েছে তা বোঝা যায়
- model-এর limitation ও bias শনাক্ত করা যায়
- কোন context-এ model ব্যবহারযোগ্য / অযোগ্য তা স্পষ্ট হয়

## Model Card কোথায় লেখা হয়?

Model card তৈরি করা হয়:

README.md

এই ফাইলটি Markdown ফরম্যাটে লেখা হয়।

## Model Card ধারণার উৎস

“Model Card” ধারণাটি এসেছে Google-এর একটি গবেষণা কাজ থেকে:

**“Model Cards for Model Reporting” – Margaret Mitchell et al.**

এই ধারণা reproducibility, reusability এবং fairness-কে গুরুত্ব দেয়।

# Model Card-এর সাধারণ কাঠামো

একটি ভাল model card সাধারণত নিচের অংশগুলো নিয়ে গঠিত হয়:

1. Model description
2. Intended uses & limitations
3. How to use
4. Limitations and bias
5. Training data
6. Training procedure
7. Evaluation metrics
8. Evaluation results

নিচে প্রতিটি অংশ ব্যাখ্যা করা হলো।

## 1) Model Description

এই অংশে model সম্পর্কে মৌলিক তথ্য থাকবে:

- Architecture (যেমন: BERT, GPT-2, DistilBERT)
- Version
- কোনো research paper থেকে এসেছে কি না
- Original implementation আছে কি না
- Author
- Copyright / License
- Training সম্পর্কে সাধারণ তথ্য
- গুরুত্বপূর্ণ disclaimer

এটা model-এর পরিচয় অংশ।

## 2) Intended Uses & Limitations

এই অংশে লিখবেন:

- Model কোন কাজে ব্যবহার করার জন্য বানানো
- কোন language / domain / field-এ ব্যবহারযোগ্য
- কোন ক্ষেত্রে ব্যবহার করা উচিত না
- কোথায় performance খারাপ হতে পারে

এটা ভুল ব্যবহার প্রতিরোধে গুরুত্বপূর্ণ।

### 3) How to Use

এখানে ব্যবহার উদাহরণ দিতে হবে:

- `pipeline()` দিয়ে ব্যবহার
- `model + tokenizer class` দিয়ে ব্যবহার
- `sample code snippet`

এই অংশ ব্যবহারকারীকে দ্রুত শুরু করতে সাহায্য করে।

### 4) Limitations and Bias

এই অংশে উল্লেখ করবেন:

- সম্ভাব্য bias (ডেটা ভিত্তিক)
- demographic imbalance
- domain limitation
- ethical concern

এটা responsible AI প্রকাশের জন্য গুরুত্বপূর্ণ।

### 5) Training Data

এখানে লিখবেন:

- কোন dataset(s) ব্যবহার হয়েছে
- dataset-এর সংক্ষিপ্ত বর্ণনা
- public নাকি private dataset

### 6) Training Procedure

Reproducibility-এর জন্য গুরুত্বপূর্ণ তথ্য দিন:

- কত epoch train হয়েছে
- batch size
- learning rate
- optimizer
- preprocessing steps
- postprocessing steps

যত বেশি স্বচ্ছতা, তত বেশি বিশ্বাসযোগ্যতা।

## 7) Metrics (Variables and Metrics)

এখানে উল্লেখ করবেন:

- কোন evaluation metric ব্যবহার করেছেন (accuracy, F1, BLEU, ROUGE, ইত্যাদি)
- কোন dataset split (train/validation/test)
- কোন dataset-এ measure করেছেন

এতে অন্য model-এর সাথে তুলনা করা সহজ হয়।

## 8) Evaluation Results

এখানে লিখবেন:

- Model কত performance দিয়েছে
- যদি decision threshold ব্যবহার হয়, threshold উল্লেখ করুন
- প্রয়োজনে বিভিন্ন threshold-এ performance দিন

## ভালো Model Card-এর উদাহরণ

- `bert-base-cased`
- `gpt2`
- `distilbert`

এগুলো Hugging Face Hub-এ গিয়ে দেখলে ভালো ধারণা পাওয়া যাবে।

## Model Card Metadata (Header অংশ)

Model card-এর উপরের অংশে metadata দেওয়া যায়।

Hub এই metadata পড়ে model-কে categorize করে।

উদাহরণ:

```
language: fr  
license: mit  
datasets:- oscar
```

এর মানে:

- Model ফরাসি ভাষার

- MIT license
- Oscar dataset-এ trained

## **Metadata** দিয়ে কী নির্ধারণ করা যায়?

- Language
- License
- Tags
- Dataset
- Metrics
- Evaluation results

Hub এই metadata ব্যবহার করে filtering ও categorization করে।