

Introduction

Chapter 3-এ আপনি প্রথমবারের মতো **Datasets** লাইব্রেরি ব্যবহার করেছেন। সেখানে model fine-tuning করার সময় তিনটি প্রধান ধাপ দেখেছিলেন:

1. Hugging Face Hub থেকে একটি dataset load করা
2. `Dataset.map()` ব্যবহার করে ডেটা preprocess করা
3. Metric load করে performance হিসাব করা

কিন্তু এগুলো আসলে Datasets লাইব্রেরির ক্ষমতার খুবই সামান্য অংশ।

এই অধ্যায়ে কী শিখবেন?

এই অধ্যায়ে আমরা Datasets লাইব্রেরিকে গভীরভাবে (deep dive) বুঝব। নিচের গুরুত্বপূর্ণ প্রশ্নগুলোর উত্তর খুঁজে বের করব:

1) যদি আপনার **dataset Hub**-এ না থাকে তাহলে কী করবেন?

সব dataset Hugging Face Hub-এ পাওয়া যায় না। তখন লোকাল ফাইল, CSV, JSON বা অন্য উৎস থেকে dataset কীভাবে load করতে হয় তা শিখবেন।

2) Dataset কীভাবে **slice** এবং **manipulate** করবেন?

- Dataset-এর নির্দিষ্ট অংশ কীভাবে ব্যবহার করবেন?
- Train/validation split কীভাবে করবেন?
- Filtering, selecting, shuffling ইত্যাদি কীভাবে করবেন?
- যদি Pandas ব্যবহার করতে হয়, তখন কীভাবে convert করবেন?

3) Dataset যদি খুব বড় হয়?

যদি dataset এত বড় হয় যে আপনার ল্যাপটপের RAM শেষ হয়ে যায়, তখন কী করবেন?

এই অধ্যায়ে বড় dataset দক্ষভাবে handle করার কৌশল শিখবেন।

4) “Memory Mapping” এবং “Apache Arrow” কী?

Datasets লাইব্রেরি performance ও efficiency বাড়াতে:

- **Memory mapping**
- **Apache Arrow**

ব্যবহার করে। এগুলো কীভাবে কাজ করে এবং কেন গুরুত্বপূর্ণ—তা ব্যাখ্যা করা হবে।

5) নিজের **Dataset** তৈরি করে **Hub**-এ আপলোড করবেন কীভাবে?

আপনি কীভাবে:

- নিজের dataset তৈরি করবেন
- সেটিকে structure করবেন
- Hugging Face Hub-এ publish করবেন

এটিও এই অধ্যায়ে শেখানো হবে।