

1 Dataset-এ নতুন Column তৈরি করা (Creating new columns)

ধরা যাক আমাদের কাছে অনেক **customer review** আছে।

একেকটা review হতে পারে:

- ছোট: "Great!"
- বড়: অনেকগুলো sentence

অনেক সময় **review** কত বড় (কত শব্দ আছে) এটা জানা দরকার হয়। কারণ:

- খুব ছোট review তথ্যবহুল না
- খুব বড় review আলাদা ভাবে handle করতে হয়

তাই আমরা প্রতিটি review-এর **word count** বের করবো।

2 Word Count বের করার Function

প্রথমে আমরা একটি function লিখি।

```
def compute_review_length(example):  
    return {"review_length": len(example["review"].split())}
```

এখানে কী হচ্ছে?

example

example হলো dataset এর একটি row।

যেমন একটি row হতে পারে:

```
{  
  'review': "It has no side effect I take it daily"  
}
```

example["review"]

এটা review text বের করছে।

"It has no side effect I take it daily"

split()

example["review"].split()

এটা sentence কে **space** দিয়ে ভেঙে শব্দের **list** বানায়।

ফলাফল:

```
["It", "has", "no", "side", "effect", "I", "take", "it", "daily"]
```

len()

len(...)

এটা শব্দের সংখ্যা গুনে।

9

return

শেষে আমরা dictionary return করি:

```
{"review_length": 9}
```

মানে নতুন একটি column তৈরি হবে যার নাম **review_length**।

3 Dataset.map() দিয়ে নতুন Column যোগ করা

এখন function টি dataset-এ apply করি।

```
drug_dataset = drug_dataset.map(compute_review_length)
```

map() কী করে?

`Dataset.map()`

dataset এর প্রতিটি **row**-এর উপর **function** চালায়।

ফলে প্রতিটি row-এ একটি নতুন column যোগ হবে।

Result Example

```
drug_dataset["train"][0]
```

Output:

```
{
  'patient_id': 206461,
  'drugName': 'Valsartan',
  'condition': 'left ventricular dysfunction',
  'review': '"It has no side effect, I take it in combination of Bystolic 5 Mg and Fish Oil"',
  'rating': 9.0,
  'date': 'May 20, 2012',
  'usefulCount': 27,
  'review_length': 17
}
```

এখানে নতুন column এসেছে:

```
review_length: 17
```

মানে review-এ ১৭টা শব্দ আছে।

4 Dataset.sort() দিয়ে Review গুলো সাজানো

এখন আমরা দেখতে চাই:

- কোন review সবচেয়ে ছোট
- কোন review সবচেয়ে বড়

তাই sort করি।

```
drug_dataset["train"].sort("review_length")[:3]
```

এখানে:

```
sort("review_length")
```

মানে **review_length** অনুযায়ী সাজাও।

তারপর

```
[:3]
```

মানে প্রথম ৩টা **row** দেখাও।

Output

```
review: "Excellent."
```

```
review_length: 1
```

```
review: "useless"
```

```
review_length: 1
```

```
review: "ok"
```

```
review_length: 1
```

মানে কিছু review মাত্র ১ শব্দের।

সমস্যা

এগুলো sentiment analysis এ চলতে পারে।

কিন্তু যদি আমরা **condition predict** করতে চাই, তাহলে এগুলো খুব useful না।

5 Alternative: add_column()

আরেকভাবে column যোগ করা যায়।

```
Dataset.add_column()
```

এটা ব্যবহার করা হয় যখন:

- আপনার কাছে আগে থেকেই list আছে
- map ব্যবহার করা কঠিন

Example:

```
dataset.add_column("review_length", list_of_lengths)
```

6 ছোট Review গুলো Filter করা

এখন আমরা খুব ছোট review বাদ দিবো।

ধরি:

৩০ শব্দের কম review বাদ

Code

```
drug_dataset = drug_dataset.filter(lambda x: x["review_length"] > 30)
```

filter() কী করে?

Dataset থেকে **condition** অনুযায়ী **row** রাখে।

এখানে condition:

```
review_length > 30
```

মানে:

31 শব্দ → থাকবে

50 শব্দ → থাকবে

10 শব্দ → বাদ যাবে

Dataset Size

```
print(drug_dataset.num_rows)
```

Output:

train: 138514

test: 46108

মানে প্রায় ১৫% **review** বাদ গেছে।

7 Largest Review খুঁজে বের করা

সবচেয়ে বড় review দেখতে চাইলে:

```
drug_dataset["train"].sort("review_length", reverse=True)
```

এখানে:

```
reverse=True
```

মানে **descending order**।

অর্থাৎ:

largest → smallest

8 HTML Character সমস্যা

অনেক dataset-এ HTML character থাকে।

যেমন:

```
I&#039;m happy
```

এখানে

```
&#039;
```

মানে '

Example

```
import html
```

```
text = "I&#039;m a transformer called BERT"  
html.unescape(text)
```

Output:

I'm a transformer called BERT

9 Dataset-এর সব Review Clean করা

এখন dataset-এর সব review clean করবো।

```
drug_dataset = drug_dataset.map(  
    lambda x: {"review": html.unescape(x["review"])}  
)
```

এখানে:

- 1 প্রতিটি review নেওয়া হচ্ছে
- 2 `html.unescape()` চালানো হচ্ছে
- 3 clean review আবার dataset-এ বসানো হচ্ছে