

Dataset.map() কী?

`Dataset.map()` হলো এমন একটি মেথড যা ডেটাসেটের প্রতিটি **example**-এর উপর একটি ফাংশন প্রয়োগ করে।

উদাহরণ:

```
dataset.map(function)
```

এখানে একটা করে **example** ফাংশনে যায়।

batched=True কী?

যখন `batched=True` ব্যবহার করা হয়, তখন একটা করে না গিয়ে অনেকগুলো **example** একসাথে ফাংশনে যায়।

ডিফল্ট batch size ≈ 1000

উদাহরণ:

আগে

```
review1 -> function
```

```
review2 -> function
```

এখন

```
[review1, review2, ... review1000] -> function
```

এতে processing অনেক দ্রুত হয়।

batched=True হলে data কেমন হয়?

`batched=False`

```
{"review": "This drug is good"}
```

`batched=True`

```
{"review": ["text1", "text2", "text3"]}
```

মানে value **list** হয়ে যায়।

Tokenization উদাহরণ

```
from transformers import AutoTokenizer

tokenizer = AutoTokenizer.from_pretrained("bert-base-cased")

def tokenize_function(examples):
    return tokenizer(examples["review"], truncation=True)

tokenized_dataset = drug_dataset.map(tokenize_function, batched=True)
```

কেন **batched=True** দ্রুত?

কারণ:

একসাথে অনেক data process হয়

Fast tokenizer (Rust language) parallel processing ব্যবহার করে

Result:

Option	Fast
batched=True	~10 s
batched=False	~59 s

num_proc কী?

num_proc ব্যবহার করলে **multiple CPU process** দিয়ে কাজ করা যায়।

```
dataset.map(function, batched=True, num_proc=8)
```

মানে ৮টা **process** একসাথে কাজ করবে।

Long text split করা

Tokenizer দিয়ে বড় text কে **multiple chunk** করা যায়।

`max_length = 128`

তাহলে

1 review → 2 বা বেশি feature

num_proc ব্যবহার করে multiprocessing

তুমি `Dataset.map()` এ CPU process বাড়াতে পারো।

```
tokenized_dataset = drug_dataset.map(  
    slow_tokenize_function,  
    batched=True,  
    num_proc=8  
)
```

মানে ৮টা **process** দিয়ে কাজ হবে।

Result:

Option	Fast	Slow
batched=True	10.8 s	
batched=True + num_proc=8	6.52 s	

Dataset size পরিবর্তন করা

`Dataset.map()` দিয়ে dataset এর **size** বাড়ানো বা কমানো যায়।

উদাহরণ:

একটা review অনেক বড় হলে tokenizer এটাকে **multiple chunks** বানাতে পারে।

`max_length = 128`

যদি review 200 token হয়

তাহলে

`chunk1 = 128`

`chunk2 = 72`

মানে

1 example -> 2 features

Error কেন আসে?

Error:

ArrowInvalid: expected length 1463 but got 1000

কারণ:

পুরানো dataset size = 1000

নতুন tokenized dataset = 1463

Mismatch হয়ে গেছে।

সমাধান ১ (পুরানো **column remove**)

```
tokenized_dataset = drug_dataset.map(  
    tokenize_and_split,  
    batched=True,  
    remove_columns=drug_dataset["train"].column_names  
)
```

সমাধান ২ (old data repeat করা)

Tokenizer return করে:

overflow_to_sample_mapping

এটা বলে:

নতুন feature কোন original sample থেকে এসেছে

তারপর সেই অনুযায়ী পুরানো data repeat করা হয়।

```
sample_map = result.pop("overflow_to_sample_mapping")
```

```
for key, values in examples.items():
```

```
    result[key] = [values[i] for i in sample_map]
```