

পুরো ব্যাপারটা সহজভাবে

Datasets-এ ডেটা ভিতরে **Apache Arrow** ফরম্যাটে থাকে।

এটা fast এবং memory-efficient।

তুমি চাইলে ওই একই ডেটা **Pandas DataFrame** আকারে দেখতে পারো, আবার কাজ শেষে DataFrame থেকে নতুন **Dataset** বানাতেও পারো।

1) `set_format("pandas")` কী করে?

```
drug_dataset.set_format("pandas")
```

এটার মানে:

- ডেটার আসল **storage format** বদলাবে না
- শুধু যখন তুমি dataset থেকে কিছু বের করবে, তখন সেটা **Pandas format**-এ return করবে

অর্থাৎ:

- ভিতরে এখনো Arrow
- বাইরে output হবে Pandas

2) কেন `drug_dataset["train"]` এখনো **Dataset**-ই থাকে?

এটাই গুরুত্বপূর্ণ অংশ।

```
drug_dataset["train"]
```

এটা এখনো **Dataset** object-ই।

কারণ `set_format()` dataset-টাকে DataFrame বানায় না,
শুধু dataset থেকে **item access** করলে output format বদলায়।

মানে `__getitem__()` method বদলায়।

3) তাহলে DataFrame পাওয়া যায় কিভাবে?

```
drug_dataset["train"][:3]
```

এখানে `[:3]` দিয়ে slice করা হয়েছে।

এই slice-এর output এখন **pandas** format হওয়ায় তুমি DataFrame পাচ্ছে।

উদাহরণ:

```
drug_dataset["train"][:3]
```

এটার output হবে ৩টা row-এর একটি **pandas.DataFrame**.

4) পুরো training set কে DataFrame বানাতে হলে

```
train_df = drug_dataset["train"][:]
```

এখানে `[:]` মানে সব row নিয়ে আসা।

তাই **train_df** হবে একটা full **pandas.DataFrame**.

5) এরপর Pandas-এর সব কাজ করতে পারো

যেহেতু **train_df** এখন Pandas DataFrame, তাই তুমি Pandas-এর feature ব্যবহার করতে পারো।

যেমন condition column-এর frequency বের করা হয়েছে:

```
frequencies = (  
    train_df["condition"]  
    .value_counts()  
    .to_frame()  
    .reset_index()  
    .rename(columns={"index": "condition", "count": "frequency"})  
)
```

এটা ধাপে ধাপে কী করছে:

train_df["condition"]

শুধু **condition** column নেয়

.value_counts()

প্রতিটি condition কয়বার আছে সেটা গুনে

.to_frame()

Series-কে DataFrame বানায়

.reset_index()

index-কে normal column বানায়

.rename(...)

column-এর নাম ঠিক করে

ফলাফল:

condition	frequency
birth control	27655
depression	8023

6) আবার **DataFrame** থেকে **Dataset** বানানো

```
from datasets import Dataset
```

```
freq_dataset = Dataset.from_pandas(frequencies)
```

এখানে `frequencies` হচ্ছে Pandas DataFrame।

`Dataset.from_pandas()` সেটা Hugging Face `Dataset`-এ convert করে।

ফলে:

- আগে ছিল `Dataset`
- তারপর হলো `DataFrame`
- আবার হলো `Dataset`

7) `reset_format()` কেন দরকার?

```
drug_dataset.reset_format()
```

এটা output format-কে আগের default-এ ফিরিয়ে দেয়।

মানে আর Pandas DataFrame return করবে না,
আবার স্বাভাবিক dataset-style output দেবে।

এটা useful যখন Pandas analysis শেষ, এখন আবার dataset operations করতে চাও।

8) Dataset save করার উপায়

লাইব্রেরিটা cache রাখে, কিন্তু তুমি চাইলে disk-এ permanently save করতে পারো।

তিনটা common format:

Format	Function
Arrow	<code>save_to_disk()</code>
CSV	<code>to_csv()</code>

JSON `to_json()`

9) Arrow format-এ save

```
drug_dataset_clean.save_to_disk("drug-reviews")
```

এতে dataset folder আকারে save হবে।

কারণ `drug_dataset_clean` সম্ভবত একটা `DatasetDict`, যেখানে:

- train
- validation
- test

এই split গুলো আছে।

প্রতিটি split-এর জন্য আলাদা `dataset.arrow` file থাকবে।

কেন **Arrow** ভালো?

কারণ এটা:

- fast
- columnar
- large dataset-এর জন্য efficient

10) Save করা dataset আবার load করা

```
from datasets import load_from_disk
```

```
drug_dataset_reloaded = load_from_disk("drug-reviews")
```

এটা disk থেকে Arrow format dataset load করে।

ফলাফল হবে আবার `DatasetDict`।

11) JSON / CSV-তে save করলে split আলাদা file করতে হয়

কারণ `DatasetDict`-কে এক ফাইলে splitসহ save করা সহজ না JSON/CSV-তে।

তাই loop চালানো হয়েছে:

```
for split, dataset in drug_dataset_clean.items():
    dataset.to_json(f'drug-reviews-{split}.jsonl')
```

এখানে:

- train → `drug-reviews-train.jsonl`
- validation → `drug-reviews-validation.jsonl`
- test → `drug-reviews-test.jsonl`

12) jsonl কী?

`jsonl` = JSON Lines

মানে:

- প্রতিটি line-এ ১টা JSON object
- ১ line = dataset-এর ১ row

উদাহরণ:

```
{"patient_id":141780,"drugName":"Escitalopram", ...}
```

এভাবে big dataset handle করা সহজ হয়।

13) JSON files থেকে আবার load করা

```
data_files = {
    "train": "drug-reviews-train.jsonl",
    "validation": "drug-reviews-validation.jsonl",
    "test": "drug-reviews-test.jsonl",
}
```

```
drug_dataset_reloaded = load_dataset("json", data_files=data_files)
```

এখানে `load_dataset()`-কে বলা হচ্ছে কোন split কোন file-এ আছে।

ফলে আবার একটা `DatasetDict` পাওয়া যাবে।

সবচেয়ে important pointগুলো

`set_format("pandas")`

শুধু output format বদলায়, data storage না

`drug_dataset["train"]`

এটা এখনও `Dataset`

`drug_dataset["train"][:]`

এটা `DataFrame` দেয়, কারণ slice করা হয়েছে

`Dataset.from_pandas(df)`

`DataFrame` থেকে `Dataset` বানায়

`reset_format()`

output format default-এ ফিরিয়ে আনে

`save_to_disk()`

Arrow format-এ save করে

`load_from_disk()`

saved Arrow dataset reload করে

খুব ছোট **example**

```
from datasets import Dataset
import pandas as pd
```

```
data = {
    "name": ["A", "B", "C"],
    "score": [80, 90, 85]
}
```

```
ds = Dataset.from_dict(data)
```

```
ds.set_format("pandas")
```

```
df = ds[:] # এখন এটা DataFrame
print(type(df))
```

```
new_ds = Dataset.from_pandas(df)
print(new_ds)
```